

# Estratégia para Padronização de Dados em Imagens Mamográficas para Análises por Radiômica

Érica M. Policarpo<sup>1</sup>, Orlando Rodrigues Jr. <sup>1</sup>, Mário O. Menezes <sup>1</sup>

<sup>1</sup>Instituto de Pesquisas Energéticas e Nucleares – IPEN – CNEN  
São Paulo, SP, Brasil.

[mo.menezes@gmail.com](mailto:mo.menezes@gmail.com), [ericamauriciopolicarpo@gmail.com](mailto:ericamauriciopolicarpo@gmail.com)

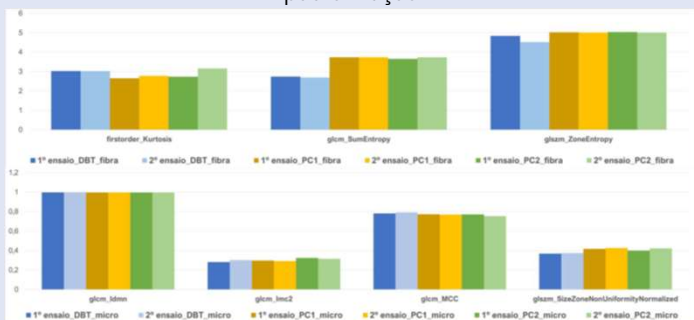
## CONTEXTO E MOTIVAÇÃO

O câncer de mama é o tipo mais comum e a maior causa de mortes em mulheres (1). Com as tecnologias de aquisição de imagens médicas no formato digital, possibilitou que ferramentas computacionais auxiliem no reconhecimento de patologias (2). Radiômica é uma dessas ferramentas, capaz de extrair dados quantitativos de fenótipos radiográficos, porém ainda não possui padronização em mamografia (3, 4).

## MATERIAIS E MÉTODOS

Foram utilizados 3 equipamentos de mamografia digital, sendo dois com tecnologia contador de fótons e um com tecnologia tomossíntese. Para a aquisição das imagens foi utilizado o simulador padrão do Colégio Americano de Radiologia (ACR), que possui os três principais achados patológicos mamográficos de interesse: Fibras, Microcalcificações e Massa.

**Figura 1.** Comportamento das características radiômicas após a padronização



Fonte: O Autor.

## OBJETIVOS

Desenvolver uma estratégia para a padronização e o planejamento inicial de análises por radiômica em imagens de mamografia digital, adquiridas em equipamentos de diferentes fabricantes.

## DESENVOLVIMENTO DO TRABALHO

No total foram adquiridas 30 imagens em 2D do simulador ACR para a análise, sendo 5 imagens em cada equipamento, divididas em 2 ensaios de aquisição, com um intervalo de um ano entre os ensaios, para avaliar a reprodutibilidade e a estabilidade da padronização. Nenhuma imagem de ser humano foi utilizada nesta pesquisa.

Foram realizados processamentos pós aquisição nas imagens do simulador ACR, de reamostragem do tamanho do pixel, discretização das intensidades de tons de cinza e segmentação das Regiões de Interesse (ROI) utilizando o software livre 3D Slicer, que possibilita também carregar o plugin Radiomics, com a biblioteca PyRadiomics, para o cálculo e extração das características radiômicas.

Para as análises estatísticas, foram utilizados os recursos e bibliotecas do Python, executados no Jupyter Notebook.

Após a padronização e segmentação das ROIs dos Test Objects nas imagens, o plugin calcula e extrai 108 características radiômicas. Aquelas que apresentaram um coeficiente de variação <15% foram consideradas como as que melhor representaram os Test Objects nesse tipo de imagem. A Figura 1 apresenta algumas das características radiômicas.

## DESAFIOS E APRENDIZADOS

A metodologia aplicada para a padronização das imagens apresentou resultados satisfatórios, possibilitando extrair e analisar dados radiômicos de imagens adquiridas com diferentes equipamentos de mamografia digital; também foi possível identificar as seguintes características com boa estabilidade e reprodutibilidade: Fibra: Energy; 10 Percentile; 90 Percentile; Kurtosis; Sum Entropy; IDM; Zone Entropy; RLNU; GLNU. Microcalcificação: 10 Percentile; 90 Percentile; Energy; MCC; Sum Entropy; IDM; IMC2; Zone Entropy; SZNU. Massa: 10 Percentile; 90 Percentile; Entropy; Kurtosis; Energy; Median; Dependence Entropy; IDM; Zone Entropy; GLNU. A aluna iniciou o projeto com compressão limitada sobre a complexidade do uso das ferramentas do software 3DSlicer, e em como extrair e analisar os dados radiômicos das imagens. No desenvolvimento da pesquisa, a aluna demonstrou capacidade em superar os desafios encontrados através de pesquisas bibliográficas, treinamentos e cursos adicionais para aprimorar seu conhecimento em teoria da formação e processamento da imagem digital, em linguagem de programação e análise de dados

## REFERÊNCIAS

1. Caleffi M, Ribeiro RA, Filho DLD, Ashton-Prolla P, Bedin AJ, Skonieski GP, et al. A model to optimize public health care and downstage breast cancer in limited-resource populations in southern Brazil. (Porto Alegre Breast Health Intervention Cohort). BMC Public Health. dezembro de 2009;9(1):83.
2. Huynh BQ, Li H, Giger ML. Digital mammographic tumor classification using transfer learning from deep convolutional neural networks. J Med Imaging. 22 de agosto de 2016;3(3):034501.
3. Ger RB, Zhou S, Chi PCM, Lee HJ, Layman RR, Jones AK, et al. Comprehensive Investigation on Controlling for CT Imaging Variabilities in Radiomics Studies. Sci Rep. 29 de agosto de 2018;8(1):13047.
4. Yip SS, Aerts HJWL. Applications and limitations of radiomics. Phys Med Biol. 7 de julho de 2016;61(13):R150–66.